

# 数学模型 Lecture Notes

Zhennan Zhou

2019 年 5 月 18 日

PRELIMINARY DRAFT. NOT FOR WIDE CIRCULATION.

参考：教材一第9，12章。

## 8 概率、随机模型

It is scientific only to say what's more likely or less likely, and not to be proving all the time what's possible or impossible.

— Richard Feynman

### 8.1 果壳中的概率 (Probability in a nutshell) 离散部分

概率空间  $(\Omega, F, P)$  是一个总测度为1的测度空间 (即  $P(\Omega) = 1$ )。

- $\Omega$  是一个非空集合，称为样本空间 (Sample Space)，他的元素称为样本输出 (Outcome)。
- $F$  是样本空间  $\Omega$  的幂集的一个非空子集 ( $\Omega$  的子集的集合)，它的元素称为事件 (Event)，事件是样本空间的子集。
- $P$  称为概率(测度)。  $P: F \rightarrow \mathbb{R}$ 。每个事件都被  $P$  赋予一个0和1之间的概率值。

随机变量  $X: \Omega \rightarrow E$  是从样本空间到可测空间  $E$  的可测函数。这门课里面，我们只考虑  $E = \mathbb{R}$ 。随机变量取值  $S \subset E$  的概率我们记为

$$\Pr(X \in S) = P(\{\omega \in \Omega | X(\omega) \in S\}).$$

离散的随机变量可以被离散的概率密度刻画：

$$\mathbf{f} = \{f_i\}; \quad f_i \geq 0, \quad i \in \mathbb{N}; \quad \sum_{i \in \mathbb{N}} f_i = 1.$$

如果  $X$  服从离散概率密度  $\mathbf{f}$ ，我们记为  $X \sim \mathbf{f}$ 。这个离散变量的 (累积) 分布函数  $\mathbf{F} = \{F_i\}$  定义为  $F_n = \sum_{i \leq n} f_i$ 。我们易知， $0 \leq F_i \leq 1$ ，而且  $F_n = \Pr(X \leq n)$ 。

关于记号做一点说明：虽然事件是样本空间的子集，但是，我们也习惯的用随机变量相对应的表示，比如事件  $\{\omega \in \Omega | u < X(\omega) \leq v\}$ ，这个事件也简写为  $u < X \leq v$ 。

条件概率  $P(A|B)$  是指事件  $A$  在另外一个事件  $B$  已经发生条件下的发生概率，定义为

$$P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

两个事件A和B是（统计）独立的，当且仅当  $P(A \cap B) = P(A)P(B)$ 。易知，如果A和B是独立事件， $P(A|B) = P(A)$ ,  $P(B|A) = P(B)$ 。

一般的，根据  $P(A \cap B) = P(A)P(B|A) = P(B)P(A|B)$ ，我们得到贝叶斯公式

$$P(A|B) = \frac{P(A)P(B|A)}{P(B)}.$$

（离散）随机变量的期望（或称均值），是随机变量在概率分布下的平均值。我们用  $\mathbf{E}$  表示期望，

$$\mathbf{E}X = \sum_i X_i f_i.$$

有时候，我们也用  $\bar{X}$  表示期望。我们也可以对随机变量的函数求期望。比如，方差定义为

$$\text{Var}(X) = D(X) = \mathbf{E}(X - \mathbf{E}X)^2 = \mathbf{E}(X^2) - (\mathbf{E}X)^2.$$

最后，随机过程是指如下的一族的随机变量

$$\{X(t) : t \in T\}.$$

这里， $T$  是一个指标集，可以是连续的，也可以离散的。如果  $t \in \mathbb{R}$ ，它常被理解为时间，而  $X(t)$  是某个可观测量在时间  $t$  时对应的随机变量。有时候，人们也会把一个随机过程写成  $\{X(t, \omega) : t \in T\}$ ，表明它其实是  $t \in T$  和  $\omega \in \Omega$  的二元函数。

## 8.2 初等概率模型举例：随机人口模型

时刻  $t$  的人口用随机变量  $X(t)$  表示， $X(t)$  只取整数值。记  $P_n(t)$  是  $X(t) = n$  的概率， $n = 0, 1, 2, \dots$ 。下面我们对出生和死亡的概率做出适当的假设，寻求  $P_n(t)$  的变化规律，并由此得到  $X(t)$  的期望和方差。

若  $X(t) = n$ ，对于充分小的时间  $\Delta t$ ，我们对人口在  $t$  到  $t + \Delta t$  的出生和死亡做如下的假设：

- 出生一人的概率与  $\Delta t$  成正比，记为  $b_n \Delta t$ ，出生两人及以上的概率是  $o(\Delta t)$ 。且  $b_n$  与  $n$  成正比，记为  $b_n = \lambda n$ 。
- 死亡一人的概率与  $\Delta t$  成正比，记为  $d_n \Delta t$ ，出生两人及以上的概率是  $o(\Delta t)$ 。且  $d_n$  与  $n$  成正比，记为  $d_n = \mu n$ 。
- 出生死亡是相互独立的随机事件。

于是我们得到，

$$P_n(t + \Delta t) = P_{n-1}(t)b_{n-1}\Delta t + P_{n+1}(t)d_{n+1}\Delta t + P_n(t)(1 - b_n\Delta t - d_n\Delta t) + o(\Delta t).$$

于是，我们得到如下的微分方程

$$\frac{dP_n}{dt} = \lambda(n-1)P_{n-1} + \mu(n+1)P_{n+1} - (\lambda + \mu)nP_n. \quad (8.1)$$

如果，在初始时刻（ $t=0$ ）人口为确定的数量  $n_0$ ，则  $P_n(t)$  的初始条件为

$$P_{n_0}(0) = 1, \quad P_n(0) = 0, \quad n \neq n_0. \quad (8.2)$$

求解这些方程非常复杂，但是如果我们只关心  $X(t)$  的期望（以下简记  $E(t)$ ）和方差（以下简记  $D(t)$ ），则我们可以由(8.1)和(8.2)直接得到。根据期望的定义， $E(t) = \sum_n nP_n(t)$ 。我们可以得到  $E(t)$  满足的方程

$$\frac{dE}{dt} = \lambda \sum_{n=1}^{\infty} n(n-1)P_{n-1} + \mu \sum_{n=1}^{\infty} n(n+1)P_{n+1} - (\lambda + \mu) \sum_{n=1}^{\infty} n^2 P_n.$$

经过化简，我们得到

$$\frac{dE}{dt} = (\lambda - \mu)E.$$

而它的初始条件为 $E(0) = n_0$ 。所以，我们得到方程的解

$$E(t) = n_0 e^{(\lambda - \mu)t}.$$

注意，这个形式就和非随机的模型完全一致了。

对于方差 $D(t)$ ，按照定义 $D(t) = \sum_{n=1}^{\infty} n^2 P_n(t) - E^2(t)$ ，可以推出（练习）


$$D(t) = n_0 \frac{\lambda + \mu}{\lambda - \mu} e^{(\lambda - \mu)t} [e^{(\lambda - \mu)t} - 1].$$

### 8.3 马氏链模型和数学理论

在考虑随机动态系统时，系统在每个时刻所处的状态是随机的，从这个时期到下一个时期的状态按照一定的概率进行转移，并且下个时期的状态这个时期的状态和转移概率，与以前各个时期的状态无关，这种性质称为无后效性，或马尔科夫（Markov）性。这种随机转移过程通常用马氏链模型来描述。

#### 8.3.1 引例

某大学有三个食堂A、B、C。调查显示：在食堂A就餐的人中 $p_{aa}$ 部分仍然回到食堂A，有 $p_{ab}$ 部分选择食堂B， $p_{ac}$ 部分选择食堂C；在食堂B就餐的人中 $p_{ba}$ 部分仍然回到食堂B，有 $p_{ba}$ 部分选择食堂A， $p_{bc}$ 部分选择食堂C；在食堂C就餐的人中 $p_{cc}$ 部分仍然回到食堂C，有 $p_{ca}$ 部分选择食堂A， $p_{cb}$ 部分选择食堂B；如图所示。



- 令 $A_n$ 为第 $n$ 天在食堂A就餐的人数比例；
- 令 $B_n$ 为第 $n$ 天在食堂B就餐的人数比例；
- 令 $C_n$ 为第 $n$ 天在食堂C就餐的人数比例。

于是我们有

$$\pi_{n+1}^T := \begin{pmatrix} A_{n+1} \\ B_{n+1} \\ C_{n+1} \end{pmatrix} = \begin{pmatrix} p_{aa}A_n + p_{ba}B_n + p_{ca}C_n \\ p_{ab}A_n + p_{bb}B_n + p_{cb}C_n \\ p_{ac}A_n + p_{bc}B_n + p_{cc}C_n \end{pmatrix} = \begin{pmatrix} p_{aa} & p_{ba} & p_{ca} \\ p_{ab} & p_{bb} & p_{cb} \\ p_{ac} & p_{bc} & p_{cc} \end{pmatrix} \begin{pmatrix} A_n \\ B_n \\ C_n \end{pmatrix} =: P^T \pi_n^T = (\pi_n P)^T.$$

### 8.3.2 马氏链选讲

我们回忆到, 对于离散的时间  $t = 0, 1, \dots$  的每一个  $t$  对应一个随机变量  $\xi_t(\omega)$ , 我们把  $\{\xi_0, \xi_1, \dots, \xi_n, \dots\}$  这样一个随机变量的序列叫做离散时间的随机过程。

所有  $\xi_n(\omega)$  具有公共的取值集合, 我们把此集合叫做状态空间, 记为  $S$ , 其元素称为状态。

离散时间离散状态的随机过程  $\{\xi_n, n \geq 0\}$ , 状态空间  $S$  为有限或者可数集合, 如果满足

$$\Pr(\xi_{n+1} = j | \xi_n = i, \xi_{n-1} = i_{n-1}, \dots, \xi_0 = i_0) = \Pr(\xi_{n+1} = j | \xi_n = i),$$

称其为一个离散时间马氏链, 其中的条件概率  $\Pr(\xi_{n+1} = j | \xi_n = i)$  称为其在时刻  $n$  处的转移概率  $p_{ij}(n)$ ,  $P(n) = (p_{ij}(n))$  称为时刻  $n$  处的转移概率矩阵。

如果马氏链的转移矩阵与出发时刻无关, 即  $P(n)$  与  $n$  无关, 则称此马氏链是时齐的。这时可将转移概率矩阵简记为  $P = (p_{ij})$ 。通常不特别说明, 马氏链就指时齐马氏链。

对于状态空间有限的情况, 马氏链的基本方程为

$$a_i(n+1) = \sum_{j=1}^k a_j(n) p_{ji}, \quad i = 1, \dots, k.$$

这里, 我们要求

$$\sum_{j=1}^k a_j(n) = 1, \quad n = 0, 1, \dots$$

$$p_{ij} \geq 0, \quad i, j = 1, \dots, k. \quad \sum_{j=1}^k p_{ij} = 1, \quad i = 1, \dots, k.$$

如果我们记状态概率向量

$$\mathbf{a}(n) = (a_1(n), \dots, a_k(n)), \quad n = 0, 1, \dots$$

则我们有

$$\mathbf{a}(n+1) = \mathbf{a}(n)P, \quad \mathbf{a}(n) = \mathbf{a}(0)P^n.$$

状态空间  $S$  上的一个概率分布称为转移概率矩阵  $P$  的不变概率分布(简称不变分布), 如果

$$\pi P = \pi, \quad \sum_{j=1}^k \pi_j = 1, \quad \pi_j \geq 0, \quad j = 1, \dots, k.$$

注意, 这时候,  $\pi^T$  可以看作是  $P^T$  特征值为 1 的特征向量, 即

$$P^T \pi^T = 1 \pi^T.$$

**例子 1.** 考虑如下转移矩阵

$$P = \begin{pmatrix} 1-a & a \\ b & 1-b \end{pmatrix}, \quad 0 \leq a, b \leq 1, a+b > 0.$$

特征值为 1 和  $1-(a+b)$ , 相应的特征向量为

$$\begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \begin{pmatrix} a \\ -b \end{pmatrix}.$$

于是有相似变换

$$\begin{aligned} P &= \begin{pmatrix} 1-a & a \\ b & 1-b \end{pmatrix} \\ &= \begin{pmatrix} 1 & a \\ 1 & -b \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1-a-b \end{pmatrix} \begin{pmatrix} 1 & a \\ 1 & -b \end{pmatrix}^{-1}. \end{aligned}$$

通过计算，我们容易得到

$$\begin{pmatrix} 1 & a \\ 1 & -b \end{pmatrix}^{-1} = \frac{1}{a+b} \begin{pmatrix} b & a \\ 1 & -1 \end{pmatrix}.$$

于是，

$$\begin{aligned} P^n &= \begin{pmatrix} 1 & a \\ 1 & -b \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & (1-a-b)^n \end{pmatrix} \begin{pmatrix} 1 & a \\ 1 & -b \end{pmatrix}^{-1} \\ &= \begin{pmatrix} 1 & a \\ 1 & -b \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & (1-a-b)^n \end{pmatrix} \frac{1}{a+b} \begin{pmatrix} b & a \\ 1 & -1 \end{pmatrix}. \end{aligned}$$

下面我们分三种情况讨论，

- Case A.  $0 < a+b < 2, a \neq 1, b \neq 1$ , 则所有元素非0,

$$\begin{aligned} P^n &\rightarrow \begin{pmatrix} 1 & a \\ 1 & -b \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \frac{1}{a+b} \begin{pmatrix} b & a \\ 1 & -1 \end{pmatrix} \\ &= \frac{1}{a+b} \begin{pmatrix} b & a \\ b & a \end{pmatrix}. \end{aligned}$$

容易验证，此时，不变分布为  $\pi = [\frac{b}{a+b}, \frac{a}{a+b}]$ .

- Case B.  $a = b = 0$ ,  $P$  为单位矩阵,  $P^n = P$ .
- Case C.  $a = b = 1$ , 则

$$P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad P^{2k} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I, \quad P^{2k+1} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} = P.$$

此时  $P^n$  极限不存在。但平均极限存在

$$\lim_{n \rightarrow +\infty} \frac{1}{n} \sum_{k=1}^n P^k = \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}.$$

下面，我们考虑一个有实际背景的例子。

**例子 2. Ehrenfest模型。** 容器内有  $2a$  个粒子，一张薄膜将容器分成对称的 A,B 两部分。将粒子穿过薄膜时占用的时间忽略不计。用  $X_0$  表示初始时 A 中的粒子数， $X_n$  表示有  $n$  个粒子穿过薄膜后 A 中的粒子数。假设  $\{X_n\}$  是马氏链，有状态空间  $I = \{0, 1, \dots, 2a\}$ 。设转移概率

$$p_{ij} = \begin{cases} \frac{2a-i}{2a}, & 0 \leq i \leq 2a-1, j = i+1, \\ \frac{i}{2a}, & 1 \leq i \leq 2a, j = i-1, \\ 0, & \text{otherwise.} \end{cases}$$

已知该马氏链的不变分布唯一存在，计算不变分布  $\pi$ 。

补充定义  $\pi_{-1} = \pi_{2a+1} = 0$ ，则方程组  $\pi P = \pi$  可以写成

$$\pi_i = \pi_{i-1}p_{i-1,i} + \pi_{i+1}p_{i+1,i}, \quad 0 \leq i \leq 2a.$$

注意到，这其实是一族的代数方程（参考第四章差分方程的一般形式），我们可以把它写成

$$\pi_{i+1} = \frac{\pi_i - \pi_{i-1}p_{i-1,i}}{p_{i+1,i}}.$$

于是，我们可以顺次计算

$$\begin{aligned} \pi_1 &= \frac{\pi_0}{p_{10}} = 2a\pi_0 = C_{2a}^1\pi_0. \\ \pi_2 &= \frac{\pi_1 - \pi_0 p_{01}}{p_{21}} = \frac{(\pi_1 - \pi_0)2a}{2} = (2a-1)a\pi_0 = C_{2a}^2\pi_0. \\ \pi_3 &= \cdots = C_{2a}^3\pi_0. \\ &\cdots \\ \pi_{2a} &= C_{2a}^{2a}\pi_0. \end{aligned}$$

利用

$$\pi_0 + \pi_1 + \cdots + \pi_{2a} = 2^{2a}\pi_0 = 1,$$

得到  $\pi_0 = 2^{-2a}$ 。历史我们得到不变分布

$$\pi_i = C_{2a}^i \left(\frac{1}{2}\right)^{2a} = C_{2a}^i \left(\frac{1}{2}\right)^i \left(\frac{1}{2}\right)^{2a-i}, \quad i = 0, \dots, 2a.$$

这是一个二项分布，说明在不变分布下，或者时间充分长以后，各个粒子的位置是相互独立的，每个粒子在 A 的概率是 1/2。

对于马氏链，我们进一步引入几个相关概念

- 可达：状态 i 称为可达状态 j，如果存在一个指标序列  $i_0 = i, i_1, \dots, i_n = j$ ，使得

$$p_{i_k, i_{k+1}} > 0 \quad k = 0, 1, \dots, n-1.$$

用转移概率矩阵来刻画 i 可达 j:

$$\exists n > 0, (p^n)_{ij} > 0.$$

这里， $(p^n)_{ij} = \Pr(\xi_n = j | \xi_0 = i)$  是 n 步转移概率。

- 吸收：如果  $p_{ii} = 1$ ，则称 i 是吸引（吸收）状态。
- 互通：状态 i 可达状态 j，而且状态 j 可达状态 i。
- 不可约：如果所有状态之间是互通的。
- 首达概率：令  $f_{ij}(n)$  为由 i 出发在 n 步后首次达到 j 的概率，简称首达概率。即

$$f_{ij}^{(n)} = \Pr(\xi_n = j, \xi_m \neq j, m = 1, \dots, n-1 | \xi_0 = i).$$

- 令  $f_{ij}^*$  是从 i 出发到达 j 的概率，即

$$f_{ij}^* = \sum_{n=1}^{\infty} f_{ij}^{(n)} \leq 1.$$

- 常返性：马氏链的状态 $y$ 称为常返的，如果 $f_{ii}^* = 1$ ，否则称为暂态（非常返态）。对于常返态 $y$ ，有概率为1地发生如下事件：从 $y$ 出发的状态，经过有限时间内必定回到状态 $y$ ，即存在 $n > 0$ ，使得

$$\Pr(\xi_n = y | \xi_0 = y) = 1.$$

- 转移概率和首达概率满足如下的分解关系：

$$(p^n)_{ij} = \sum_{k=1}^n f_{ij}^{(k)} (p^{n-k})_{jj}.$$

## 8.4 随机微分方程模型简介

我们回顾，有“噪声”的常微分方程模型可以写成如下的形式：

$$\frac{dX_t}{dt} = b(t, X_t) + \sigma(t, X_t)\eta(t).$$

数学上，我们常对噪声做如下的假设

1.  $\mathbb{E}\eta(t) = 0$ ;
2.  $\eta(t)$  是平稳的(这个严格定义超出了本课的范围);
3.  $\mathbb{E}\eta(t)\eta(s) = 0$  if  $t \neq s$ .

这样的噪声被称为**白噪声**。事实上，可以证明，满足这样的 $\eta(t)$ 是不会有连续的路径的。为了理解这类方程，我们来考虑一个离散的形式：在时间点 $t_0 < t_1 \cdots$ ，我们令 $X_k = X(t_k)$ ：

$$X_{k+1} - X_k = b(t_k, X_k)\Delta t_k + \sigma(t_k, X_k) \int_{t_k}^{t_{k+1}} \eta(s) ds. \quad (8.3)$$

我们不妨引入 $V_t = V(t)$ ，使得

$$\int_{t_k}^{t_{k+1}} \eta(s) ds = V(t_{k+1}) - V(t_k) =: \Delta V_k. \quad (8.4)$$

根据 $\eta(t)$ 的性质，我们知道

1.  $\mathbb{E}V_t = 0$ ;
2. 平稳的增长;
3. 独立的增长.

而且，因为我们希望 $X_t$ 至少是连续的，所以我们要求 $V_t$ 有连续的路径。事实上，在一定意义下，唯一可能的满足上述条件的过程是布朗运动（Brownian motion, or Wiener process），而且，它还满足

- $\mathbb{E}W_t W_s = \min(s, t)$ ;
- for  $t > s$ ,  $W_t - W_s \sim N(0, t - s)$ .

于是，我们可设，

$$X_k = X_0 + \sum_{j=0}^{k-1} b(t_j, X_j) \Delta t_j + \sum_{j=0}^{k-1} \sigma(t_j, X_j) \Delta W_j, \quad (8.5)$$

然后考虑  $\Delta t_j \rightarrow 0$  的极限。假设极限存在，则我们可写成

$$X_t = X_0 + \int_0^t b(s, X_s) ds + \int_0^t \sigma(s, X_s) dW_s, \quad (8.6)$$

或者他的微分形式

$$dX_t = b(t, X_t) dt + \sigma(t, X_t) dW_t. \quad (8.7)$$

注意，布朗运动  $W_t$  其实是关于时间不可微的，因此，我们常避免写  $\frac{dW_t}{dt}$ 。但是，事实上，一些人还是会这么写……

我们需要理解在什么意义下，对于哪些随机过程  $f(s, \omega)$ （这里， $\omega$  是概率空间的参数）， $\int_0^t f(s, \omega) dW_s$  是存在的。因此，我们先考虑如下的积分

$$I = \int_0^t W_s dW_s. \quad (8.8)$$

让我们尝试在  $[k\Delta t, (k+1)\Delta t]$  等区间上用黎曼积分计算这个积分。我们考虑两种特殊的选择

A. 被积函数在区间的左端点取值

$$I^{(n)} = \sum_{k=0}^{n-1} W_{k\Delta t} (W_{(k+1)\Delta t} - W_{k\Delta t}), \quad (8.9)$$

于是，我们计算得到

$$\mathbb{E} I^{(n)} = \sum k\Delta t - k\Delta t = 0. \quad (8.10)$$

B. 被积函数在区间的中点取值

$$I^{(n)} = \sum_{k=0}^{n-1} W_{(k+\frac{1}{2})\Delta t} (W_{(k+1)\Delta t} - W_{k\Delta t}), \quad (8.11)$$

于是我们计算得到

$$\mathbb{E} I^{(n)} = \sum (k + \frac{1}{2})\Delta t - k\Delta t = \frac{t}{2}. \quad (8.12)$$

可见，在不同的逼近选择下，我们得到了不同的极限。所以，黎曼积分是并不存在的。为了解决这个问题，我们需要先决定被积函数在每个区间的逼近方式。这里，有两个常见的选择：

**定义 1** *Itô integral* 是黎曼和中被积函数在左端点取值的极限，记为

$$\int_0^t f(s, \omega) dW_s.$$

**定义 2** *Stratonovich integral* 是黎曼和中被积函数利用梯形公式取值的极限，即

$$\sum_j \frac{1}{2} (f(t_j, \omega) + f(t_{j+1}, \omega)) \Delta W_j.$$

记为

$$\int_0^t f(s, \omega) \circ dW_s.$$

在下文中，我们只考虑 Itô integral。这里，我们列举 Itô Calculus 的几个常用的性质



- 对于 Itô integral, 我们有如下的一般性结果

$$\mathbb{E} \int_0^t f(s, \omega) dW_s = 0. \quad (8.13)$$

- 对于 Itô integral, 我们有如下的 Itô isometry

$$\mathbb{E} \left( \int_0^t f(s, \omega) dW_s \right)^2 = \mathbb{E} \int_0^t f(s, \omega)^2 ds. \quad (8.14)$$

- Itô formula (Itô lemma):

Let  $X_t$  be the solution to

$$dX_t = b(t, \omega) dt + \sigma(t, \omega) dW_t$$

where  $b, \sigma$  are functions of  $(t, \omega)$ . Given  $g(t, x) \in C^2([0, \infty) \times \mathbb{R})$ . Then  $Y_t = g(t, X_t)$  satisfies the equation

$$dY_t = \frac{\partial g}{\partial t}(t, X_t) dt + \frac{\partial g}{\partial x}(t, X_t) dX_t + \frac{1}{2} \frac{\partial^2 g}{\partial x^2}(t, X_t) (dX_t)^2, \quad (8.15)$$

where  $(dX_t)^2$  is computed according to the rules

$$dt \cdot dt = dt \cdot dW_t = dW_t \cdot dt = 0, \quad dW_t \cdot dW_t = dt.$$

**例子1.** 计算  $d(\frac{1}{2} W_t^2)$ . 令  $g(t, x) = \frac{1}{2} x^2$ , 则

$$dY_t = W_t dW_t + \frac{1}{2} (dW_t)^2 = W_t dW_t + \frac{1}{2} dt.$$

**例子2. Ornstein-Uhlenbeck process.** 考虑方程

$$dX_t = -aX_t dt + \sigma dW_t, \quad X_0 = \xi. \quad (8.16)$$

注意到, 右端的第一项代表指数型衰减, 而第二项表示“波动”变化。

我们来利用积分因子法求解此问题。方程两边乘以  $e^{at}$ , 我们得到

$$d(e^{at} X_t) = e^{at} dX_t + ae^{at} X_t dt = \sigma e^{at} dW_t, \quad (8.17)$$

于是, 积分得到

$$e^{at} X_t - X_0 = \int_0^t \sigma e^{as} dW_s. \quad (8.18)$$

所以, 方程的解是

$$X_t = e^{-at} X_0 + \sigma \int_0^t e^{-a(t-s)} dW_s. \quad (8.19)$$

我们注意到, 方程对初值的“记忆”会指数型衰减。并且, 我们做如下的计算

- Mean.  $\mathbb{E} X_t = e^{-at} \mathbb{E} X_0$  指数型衰减到 0。

- Covariance. (假设初值和  $W_t$  无关)

$$\begin{aligned} \mathbb{E} X_t X_s - \mathbb{E} X_t \mathbb{E} X_s &= e^{-at} e^{-as} (\mathbb{E} X_0^2 - (\mathbb{E} X_0)^2) + \sigma^2 \mathbb{E} \left[ \int_0^s \int_0^t e^{-a(t-v)} e^{-a(s-u)} dW_u dW_v \right] \\ &= e^{-a(s+t)} \text{Var } X_0 + \sigma^2 \int_0^{s \wedge t} e^{-a(s-u)} e^{-a(t-u)} du \\ &= e^{-a(s+t)} \text{Var } X_0 + \frac{\sigma^2}{2a} (e^{-a|s-t|} - e^{-a(s+t)}). \end{aligned}$$

特别的, 我们注意到  $\lim_{t \rightarrow \infty} \text{Var } X_t = \frac{\sigma^2}{2a}$ .

**例子3. Geometric Brownian motion.** 考虑方程

$$dN_t = rN_t dt + \alpha N_t dW_t. \quad (8.20)$$

这是另外一个人口增长模型，这里  $r$  是（相对）增长系数， $\alpha$  是波动系数。这个例子也跟金融数学里面的Black-Scholes model 有关。这个意义下， $N_t$  可以理解称资产的定价， $\alpha$  可以理解为波动性。

为了解此方程，我们在两端除以  $N_t$ ，便得到

$$\frac{dN_t}{N_t} = r dt + \alpha dW_t. \quad (8.21)$$

注意，利用 Itô formula，我们有

$$d(\log N_t) = \frac{1}{N_t} dN_t - \frac{1}{2N_t^2} (dN_t)^2 = \frac{1}{N_t} dN_t - \frac{\alpha^2}{2} dt. \quad (8.22)$$

于是我们得到，

$$d(\log N_t) = \left(r - \frac{\alpha^2}{2}\right) dt + \alpha dW_t, \quad (8.23)$$

容易得出方程的解

$$N_t = N_0 e^{(r - \frac{\alpha^2}{2})t + \alpha W_t}. \quad (8.24)$$

接下来，我们来计算一下解的均值（期望）。注意到，问题的关键在于求  $Y_t := e^{\alpha W_t}$  的均值。利用 Itô formula，我们有

$$dY_t = \alpha e^{\alpha W_t} dW_t + \frac{\alpha^2}{2} e^{\alpha W_t} dt = \alpha Y_t dW_t + \frac{\alpha^2}{2} Y_t dt, \quad (8.25)$$

两边积分，并求期望，我们得到

$$\mathbb{E}Y_t = \mathbb{E}Y_0 + \frac{\alpha^2}{2} \int_0^t \mathbb{E}Y_s ds, \quad (8.26)$$

于是有

$$\frac{d}{dt} \mathbb{E}Y_t = \frac{\alpha^2}{2} \mathbb{E}Y_t. \quad (8.27)$$

显然， $\mathbb{E}Y_0 = 1$ ，于是我们有  $\mathbb{E}Y_t = e^{\frac{\alpha^2}{2}t}$ 。

最终，我们得到，

$$\mathbb{E}N_t = (\mathbb{E}N_0) e^{rt},$$

也就是说，人口数量期望的增长和变化率模型的人口增长是一样的。（注意，按照第二章的模型建立方法，我们有简单的没有随机因素的人口增长模型  $\dot{N} = rN$ 。）

### 8.4.1 Fokker-Planck equation

最后，我们换一个角度看随机微分方程。我们考虑  $X_t$  满足

$$dX_t = b(t, X_t) dt + \sigma(t, X_t) dW_t. \quad (8.28)$$

注意，对于固定的  $t$ ， $X_t$  是一个随机变量，我们令它的概率密度函数为  $\rho(x, t)$ ，那么已知了  $X_t$  的时间演化，我们如何得到  $\rho(x, t)$  的时间演化呢？

下面只给出一个形式上的推导。考虑任何一个光滑函数  $g(x)$ ，由 Ito's formula，我们有

$$\begin{aligned} dg(t, X_t) &= \frac{\partial g(t, X_t)}{\partial x} dX_t + \frac{1}{2} \frac{\partial^2 g(t, X_t)}{\partial x^2} \sigma(X_t)^2 dt \\ &= \left( \frac{\partial g(t, X_t)}{\partial x} b(X_t) + \frac{1}{2} \frac{\partial^2 g(t, X_t)}{\partial x^2} \sigma(X_t)^2 \right) dt + \frac{\partial g(t, X_t)}{\partial x} \sigma(X_t) dW_t. \end{aligned} \quad (8.29)$$

通过取期望，我们得到

$$d\mathbb{E}g(t, X_t) = \mathbb{E}\left(\frac{\partial g(t, X_t)}{\partial x}b(X_t) + \frac{1}{2}\frac{\partial^2 g(t, X_t)}{\partial x^2}\sigma(X_t)^2\right)dt. \quad (8.30)$$

利用，概率密度函数  $\rho(x, t)$ ，可以把上式表达为

$$\begin{aligned} \frac{\partial}{\partial t} \int \rho(t, x)g(x)dx &= \int \left(g'(x)b(x) + \frac{1}{2}g''(x)\sigma(x)^2\right)\rho(t, x)dx \\ &= \int g(x)\left(-\frac{\partial}{\partial x}(b(x)\rho(t, x)) + \frac{1}{2}\frac{\partial^2}{\partial x^2}(\sigma^2(x)\rho(t, x))\right)dx. \end{aligned} \quad (8.31)$$

如果我们把  $g(x)$  看作一个试验函数，由  $g$  的任意性，我们得到

$$\frac{\partial}{\partial t}\rho(t, x) = -\frac{\partial}{\partial x}(b(x)\rho(t, x)) + \frac{1}{2}\frac{\partial^2}{\partial x^2}(\sigma^2(x)\rho(t, x)). \quad (8.32)$$

这就是所谓的 forward Kolmogorov equation，又叫做 Fokker-Planck equation。我们注意，如果没有随机微分方程没有噪声项的话（即  $\sigma = 0$ ，随机微分方程变成了常微分方程），那么 Fokker-Planck equation 其实退化成了第一章（或者第三章）的守恒律方程。

本学期的课程内容全部结束了！但是数学模型的学习道路是没有终点的……